UNIVERSIDAD TECNOLÓGICA NACIONAL

INGENIERÍA INDUSTRIAL

Ciencia de Datos

TRABAJO FINAL GRUPAL: Bank Subscription

Curso N°: I5571 Grupo Nº:3

	Nombre y apellido	Legajo Nro.
1-	Federico Galdames	1468959
2-	Guadalupe Molina	1766764
3-	María González	2595710
4-	Ignacio Rasines	2026223

Equipo Docente: Kevin Dobzewicz / Santiago Chas / Lucas Mareque / Rodrigo Maranzana

Introducción y objetivos

En las campañas de marketing bancario cada contacto implica un costo y solo una parte de los clientes acepta la oferta. Estimar la probabilidad de suscripción permite priorizar a los clientes con mayor propensión a responder y orientar los recursos de la campaña.

En este trabajo se busca predecir la suscripción a una campaña bancaria a partir de datos de 45.211 clientes, que incluyen características demográficas, información financiera y antecedentes de contacto con el banco. Para ello, se aplican modelos de aprendizaje supervisado que permiten estimar si un cliente se suscribirá y analizar qué variables tienen mayor peso en la predicción.

Los objetivos son:

- Realizar en Python un análisis exploratorio de datos (EDA) para caracterizar el conjunto de datos, identificar valores faltantes y examinar la relación de las variables con la suscripción.
- Desarrollar en Python un *pipeline* de *machine learning* que integre el preprocesamiento de los datos y el entrenamiento de modelos de clasificación para predecir la variable subscription.
- Aplicar el análisis de componentes principales (PCA) para reducir la dimensionalidad, volver a entrenar los modelos con los componentes obtenidos y comparar su desempeño con el de los modelos sin reducción.

Descripción del dataset

Cada fila del dataset corresponde a un cliente y cada columna a una de sus características. Además de la variable a predecir (Subscription, que vale 1 si el cliente se suscribió y 0 si no), hay 16 variables que pueden agruparse en tres tipos de información:

- Datos del cliente: edad, tipo de empleo, estado civil, nivel educativo, deuda en mora, saldo promedio anual, préstamo hipotecario y préstamo personal
- Campaña actual: medio de contacto, día y mes del último contacto, duración de la última llamada y cantidad de contactos en la campaña.
- Campañas anteriores: días desde el último contacto previo (pdays, con -1= sin contacto previo), cantidad de contactos previos y resultado de la campaña anterior

En total hay 7 variables numéricas y 9 categóricas. No se encontraron filas duplicadas y la variable objetivo está desbalanceada, ya que solo 5.289 clientes (11,7%) se suscribieron.

Análisis exploratorio de datos

El primer paso fue revisar la calidad de los datos. Si bien no se encontraron clientes duplicados, diez variables tenían valores faltantes, entre el 11% y el 17% de los registros según la variable. Como los faltantes están repartidos entre clientes distintos, eliminar a todos los que tuvieran al menos un dato vacío habría dejado solo el 24% de la base. Por eso se decidió completarlos (imputarlos) de la siguiente forma: las variables numéricas con la mediana, que no se ve afectada por los extremos, y las categóricas con la opción más frecuente. Cabe destacar que antes de tomar esta decisión se comprobó que los clientes

con datos faltantes se suscriben en la misma proporción que el resto, lo que indica que los faltantes no representan un grupo particular de clientes. En el caso de los días transcurridos desde el último contacto previo, se observó que todos los clientes nunca contactados tenían el valor -1 o un dato vacío, por lo que estos vacíos pudieron completarse con certeza. También se detectaron valores extremos como saldos muy altos, llamadas muy largas o clientes contactados decenas de veces. Al analizarlos se concluyó que son casos reales y por eso se conservaron.

Por otra parte, el desbalance de la variable objetivo tiene una consecuencia muy importante, ya que un modelo que respondiera siempre que el cliente no se suscribe acertaría en el 88,3% de los casos, pero no encontraría a ninguno de los clientes que el banco busca. Debido a esto se descartó el porcentaje de aciertos para juzgar el modelo, y se priorizaron medidas que indican cuántos de los clientes interesados logra detectar.

Para identificar qué factores se asocian a la suscripción se calculó, para cada grupo de clientes, el porcentaje que aceptó la oferta, y se lo comparó con el promedio general de 11,7 %. La duración de la llamada resultó el factor más fuerte, ya que en las llamadas de menos de un minuto casi nadie se suscribe (0,2 %), mientras que en las de más de 1.000 segundos (unos 17 minutos) lo hace el 59,8 % (Figura 1). Sin embargo, la duración solo se conoce una vez terminada la llamada, de modo que no sirve para decidir a quién llamar. Usarla con ese motivo sería un caso de fuga de información (data leakage), es decir, usar un dato que en la práctica no está disponible al momento de decidir.

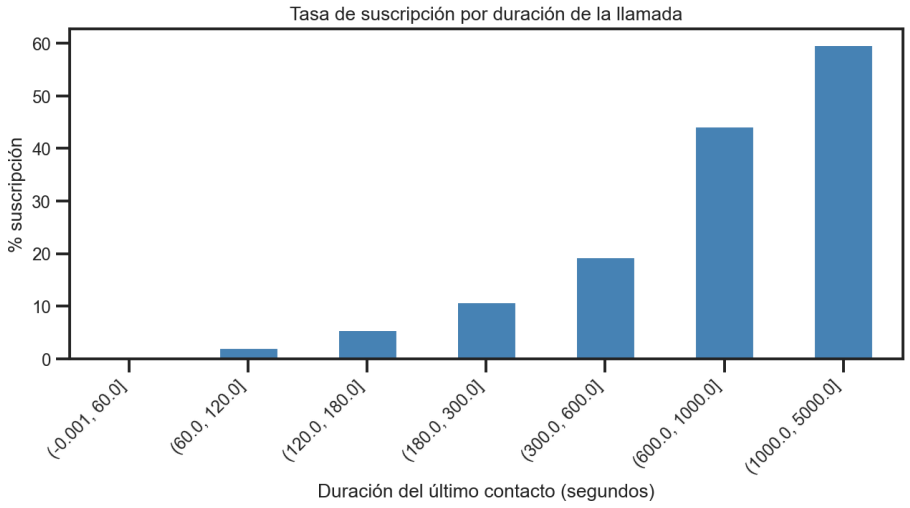


Figura 1. Porcentaje de suscripción según la duración de la llamada (en segundos).

También se observó que insistir rinde cada vez menos (14,6 % de suscripción con un contacto y 4,2 % con diez o más) y que la edad tiene una relación en forma de U: los menores de 25 y los mayores de 60 años se suscriben mucho más que los de mediana edad. El mes de contacto resultó determinante (Figura 2), se ve que en mayo se concentró el 30 % de las llamadas y tuvo la peor tasa (6,7 %), mientras que marzo, septiembre, octubre y diciembre, con pocas llamadas, superaron el 40 %, lo que sugiere que las campañas masivas son menos efectivas. Por último, los clientes que habían aceptado una campaña anterior vuelven a suscribirse en el 64,7 % de los casos.

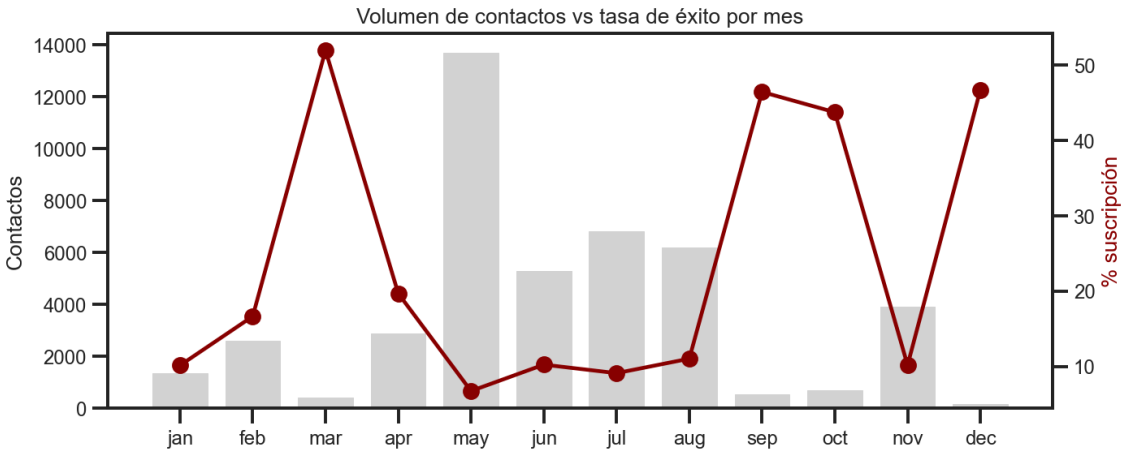


Figura 2. Cantidad de llamadas (barras) y porcentaje de suscripción (línea) por mes.

Materiales y métodos

El trabajo se realizó en Python (pandas, matplotlib, seaborn, scikit-learn y XGBoost) en tres notebooks: análisis exploratorio, preprocesamiento y machine learning. Los datos se dividieron en un 80 % para entrenamiento y un 20 % para prueba, manteniendo la proporción de suscriptores. El completado de faltantes y las demás transformaciones se calcularon solo con los datos de entrenamiento. Las variables numéricas se llevaron a una escala común y cada variable categórica se transformó en columnas de unos y ceros, una por opción, con lo que cada cliente quedó descrito por 52 columnas.

Se compararon seis modelos. La regresión logística combina las variables con distintos pesos y devuelve una probabilidad, pero solo representa relaciones lineales. KNN clasifica a cada cliente según lo que hicieron los clientes más parecidos. El árbol de decisión aplica una secuencia de preguntas sobre las variables. Random Forest promedia cientos de árboles, lo que lo hace más estable, y XGBoost también combina árboles, pero en secuencia, de modo que cada uno corrige los errores del anterior. La red neuronal organiza neuronas en capas capaces de aprender relaciones complejas. Como referencia se usó un modelo trivial que siempre predice “no se suscribe”.

La configuración de cada modelo se eligió con validación cruzada, es decir, el conjunto de entrenamiento se divide en cinco partes y el modelo se entrena cinco veces, evaluándolo cada vez en una parte distinta. Para medir el desempeño se usaron la sensibilidad (porcentaje de suscriptores que el modelo detecta), la especificidad (porcentaje de no suscriptores que descarta correctamente) y el AUC, que indica qué tan bien el modelo ordena a los clientes de más a menos probable, 0,5 equivale al azar y 1 a un orden perfecto.

Por último, se aplicó el análisis de componentes principales (PCA), que resume las 52 columnas en menos variables nuevas (componentes) conservando la mayor parte de la variabilidad de los datos. La hipótesis es que muchas columnas son redundantes y que trabajar con menos simplifica el modelo. Se volvieron a entrenar todos los modelos con las componentes que conservan el 90 % de la variabilidad.

El grupo utilizó una herramienta de inteligencia artificial como apoyo en momentos puntuales, en consultas sobre funciones, sintaxis de Python y resolución de errores de

código. El código de cada notebook fue revisado, ejecutado y ajustado por el grupo, que verificó la consistencia de los resultados y es responsable de las decisiones metodológicas y de las conclusiones presentadas.

Experimentos y resultados

Modelo	AUC	Accuracy	Sensibilidad	Especificidad	AUC con PCA	AUC sin duración
XGBoost	0,919	0,907	0,439	0,969	0,877	0,807
Random Forest	0,912	0,901	0,304	0,980	0,869	0,803
Red neuronal	0,901	0,903	0,435	0,965	0,880	0,786
Árbol de decisión	0,888	0,900	0,408	0,965	0,821	—
Regresión logística	0,883	0,900	0,304	0,979	0,851	0,770
KNN	0,876	0,896	0,214	0,987	0,854	—
Modelo trivial	0,500	0,883	0,000	1,000	—	—

Tabla 1. Resultados sobre el conjunto de prueba.

El mejor modelo fue XGBoost (AUC 0,919), seguido por Random Forest (0,912) y la red neuronal (0,901) (Tabla 1 y Figura 3). Los modelos más flexibles superaron a la regresión logística y a KNN, en línea con relaciones no lineales como la de la edad. Los resultados en prueba fueron casi iguales a los de la validación cruzada, lo que indica que los modelos no son rígidos ni memorizaron los datos de entrenamiento.

Todos los modelos muestran especificidad alta y sensibilidad baja. XGBoost detecta solo el 44 % de los suscriptores, porque por defecto recomienda llamar únicamente si la probabilidad supera el 50 %. Para definir un umbral más adecuado se usó el siguiente supuesto: cada llamada cuesta 10 € y cada suscripción deja 100 €. Así, llamar conviene cuando la probabilidad supera el 10 %, ya que desde ese punto la ganancia esperada (0,10 × 100 € = 10 €) cubre el costo. Con ese umbral la sensibilidad sube al 86 % llamando a una cuarta parte de la cartera. El accuracy baja del 91 % al 83 %, pero el beneficio estimado pasa de 39.260 € a 68.610 €, frente a 15.370 € si se llamara a todos (Figura 4).

Con PCA se necesitaron 17 componentes para conservar el 90 % de la variabilidad, pero el AUC bajó en todos los modelos, entre 0,02 y 0,07 puntos (Figura 5). Al dejar que la validación cruzada eligiera cuántas componentes usar, la mejor opción fue no aplicar PCA. Finalmente, sin la duración de la llamada el AUC de XGBoost bajó de 0,919 a 0,807; aun así, con el umbral del 10 % el modelo detecta al 70 % de los interesados llamando al 27 % de los clientes, con un beneficio estimado de 48.940 €.

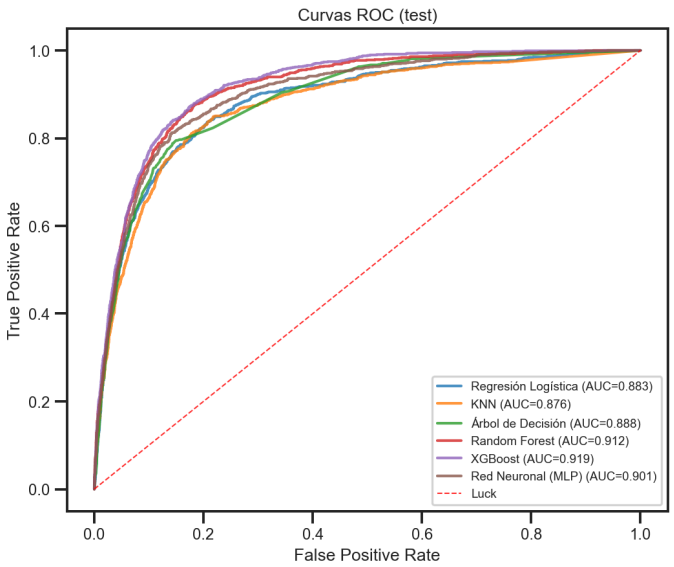


Figura 3. Curvas ROC de los seis modelos sobre el conjunto de prueba; el área bajo cada curva es el AUC.

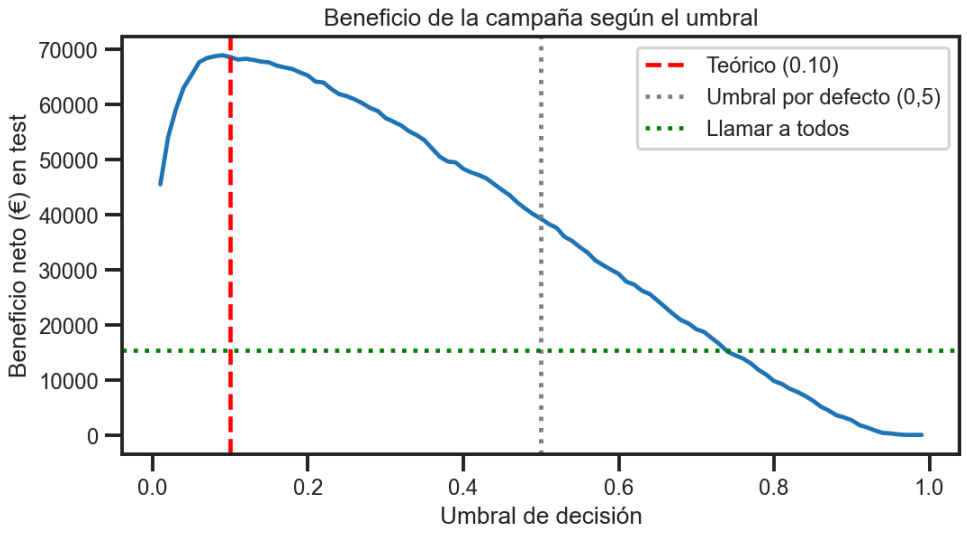


Figura 4. Beneficio estimado de la campaña según el umbral de decisión (modelo XGBoost).

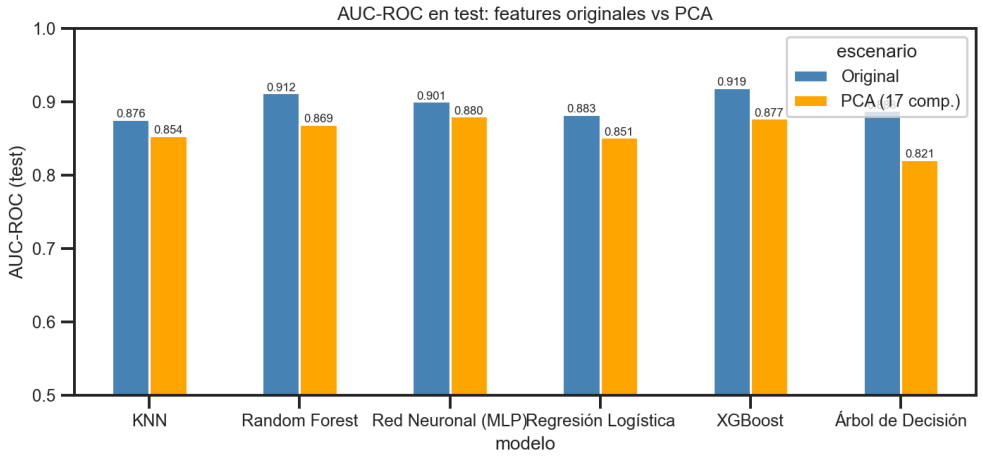


Figura 5. AUC de cada modelo con las 52 columnas originales y con PCA (17 componentes).

Discusión y conclusiones

Con clases desbalanceadas, el porcentaje de aciertos es engañoso porque un modelo que no detecta a ningún interesado acierta el 88% de las veces. Los modelos que combinan árboles (XGBoost y Random Forest) dieron los mejores resultados ya que capturan relaciones no lineales y combinaciones entre variables. También se observa que el ajuste del umbral debe realizarse con un criterio de negocio, bajar el umbral redujo el accuracy pero casi duplicó el beneficio, aunque los costos usados son supuestos que deberían validarse con el banco.

PCA no mejora la predicción porque conserva la información que más varía, no la que mejor separa a quienes se suscriben de quienes no. Características poco frecuentes pero muy informativas, como haber aceptado una campaña anterior, se pierden al reducir la dimensión. Por último, la duración de la llamada es la variable más predictiva, pero no está disponible al decidir a quién llamar, por lo que se recomienda el modelo sin ella.

Referencias

Bishop, C. M. (2006). *Pattern recognition and machine learning*. Springer.

Breiman, L. (2001). Random forests. *Machine Learning.*

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM.

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2.ª ed.). Springer.

James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An introduction to statistical learning: With applications in Python*. Springer.

Moro, S., Cortez, P., & Rita, P. (2014). A data-driven approach to predict the success of bank direct marketing campaigns. *Decision Support Systems.*

Murphy, K. P. (2022). *Probabilistic machine learning: An introduction*. MIT Press.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research.*